Analisis Perbandingan Strategi Training ResNet18 dan EfficientNet-B0 untuk Klasifikasi Citra Hewan

1. Pendahuluan

Klasifikasi citra hewan merupakan salah satu permasalahan computer vision yang membutuhkan kemampuan model dalam mengenali karakteristik visual antar kelas. Eksperimen ini membandingkan beberapa strategi pelatihan menggunakan ResNet18, yaitu training from scratch, feature extraction, progressive fine-tuning, serta pengaruh data augmentation. Selain itu digunakan EfficientNet-B0 sebagai eksperimen tambahan untuk melihat performa arsitektur yang lebih efisien.

2. Dataset dan Preprocessing

Dataset yang digunakan adalah Oxford-IIIT Pet dengan 10 kelas terpilih. Jumlah data yang digunakan sebanyak 996 gambar dengan pembagian train 697 gambar, validation 149 gambar, dan test 150 gambar.

Kelas yang digunakan: Abyssinian, Bengal, Birman, Bombay, British Shorthair, American Bulldog, Beagle, Boxer, German Shorthaired, dan Chihuahua.

Preprocessing dilakukan dengan resize, normalisasi ImageNet, serta augmentasi berupa RandomResizedCrop, RandomHorizontalFlip, RandomRotation 15 derajat, dan ColorJitter.

3. Metodologi Eksperimen

3.1 B1 - ResNet18 From Scratch

Model ResNet18 dilatih dari awal menggunakan bobot random initialization. Seluruh parameter diperbarui selama training.

3.2 B2 - ResNet18 Feature Extraction

Backbone ResNet18 pretrained ImageNet dibekukan dan hanya classifier yang dilatih.

3.3 B3 - Progressive Fine-Tuning

Layer tertentu pada backbone dibuka kembali agar fitur pretrained dapat beradaptasi terhadap dataset target.

3.4 B4 - Data Augmentation

Dilakukan perbandingan kondisi tanpa augmentation dan dengan augmentation.

3.5 B5 - EfficientNet-B0

EfficientNet-B0 digunakan sebagai model tambahan dengan jumlah parameter lebih kecil.

4. Hasil Eksperimen

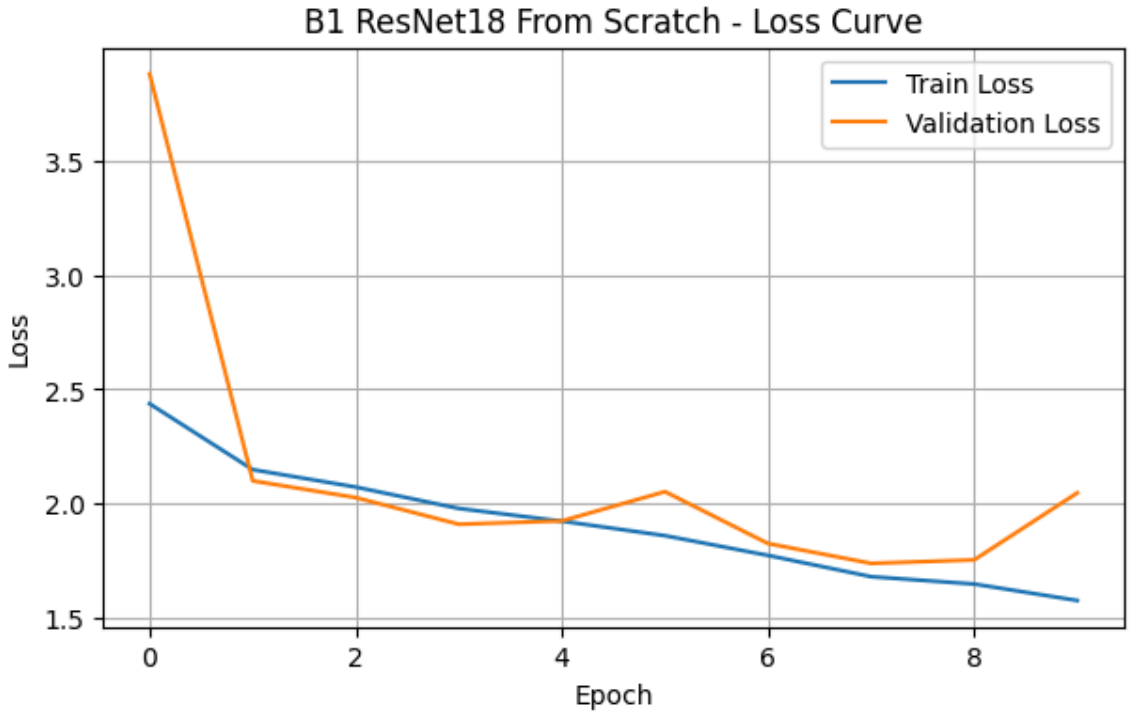
Tabel perbandingan hasil eksperimen:

Model	Strategi	Total Params	Trainable Params	Test Accuracy	Macro F1	Training Time
B1 ResNet18	Scratch	11,181,642	11,181,642	0.3600	0.3395	98.27 s
B2 ResNet18	Feature Extraction	11,181,642	5,130	0.9867	0.9867	89.92 s
B3 ResNet18	Progressive Fine-Tuning	11,181,642	8,398,858	0.9867	0.9866	56.80 s
B5 EfficientNet-B0	Feature Extraction	4,020,358	12,810	0.9733	0.9733	89.42 s

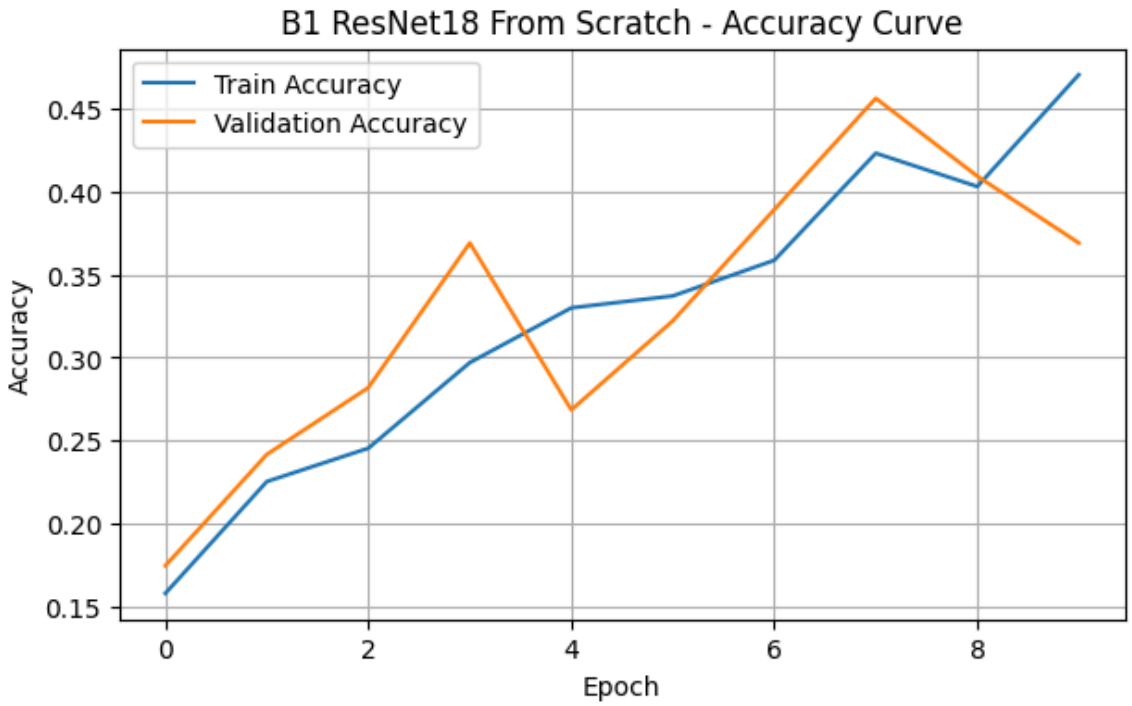
Analisis Pengaruh Augmentation (B4) **:**

Kondisi	Test Accuracy	Macro F1
Tanpa Augmentation	0.9800	0.97998
Dengan Augmentation	0.9733	0.9735

4.1 Training Curve B1

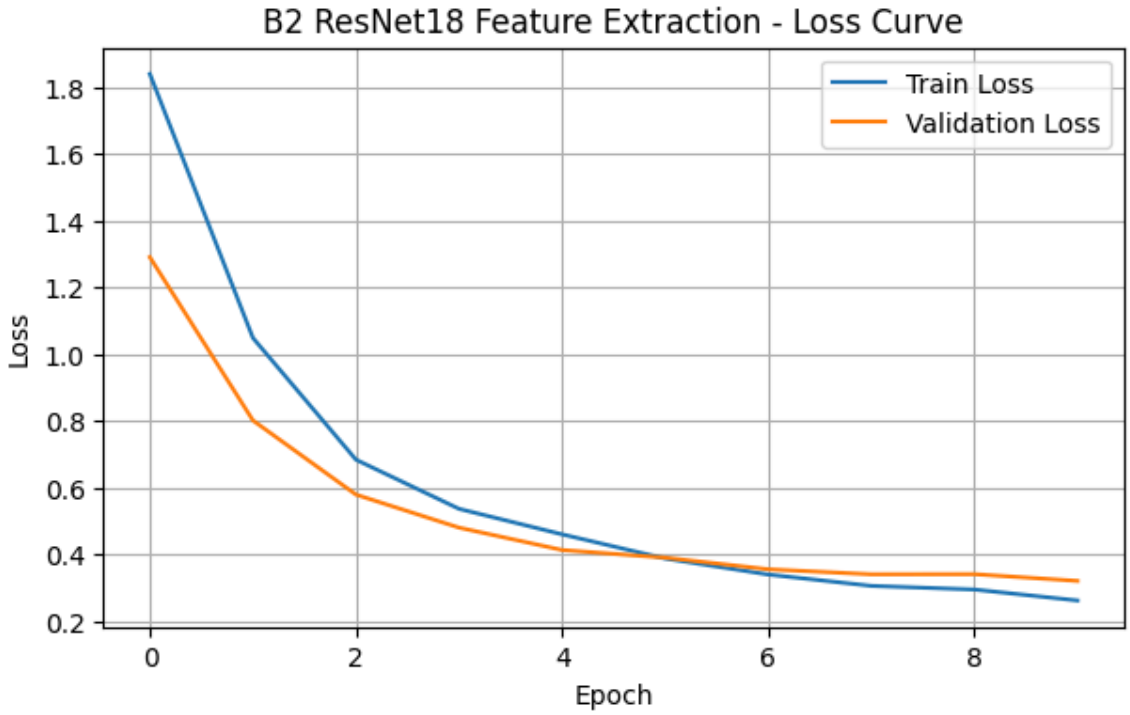


Berdasarkan grafik loss training B1, terlihat bahwa nilai loss training mengalami penurunan secara bertahap selama proses pelatihan. Hal ini menunjukkan bahwa model mulai mempelajari pola dari dataset yang diberikan. Namun, penurunan validation loss tidak terlalu stabil dan mengalami peningkatan pada beberapa epoch akhir. Kondisi ini menunjukkan bahwa model from scratch mengalami kesulitan dalam melakukan generalisasi karena seluruh fitur harus dipelajari dari awal menggunakan jumlah data yang relatif terbatas.

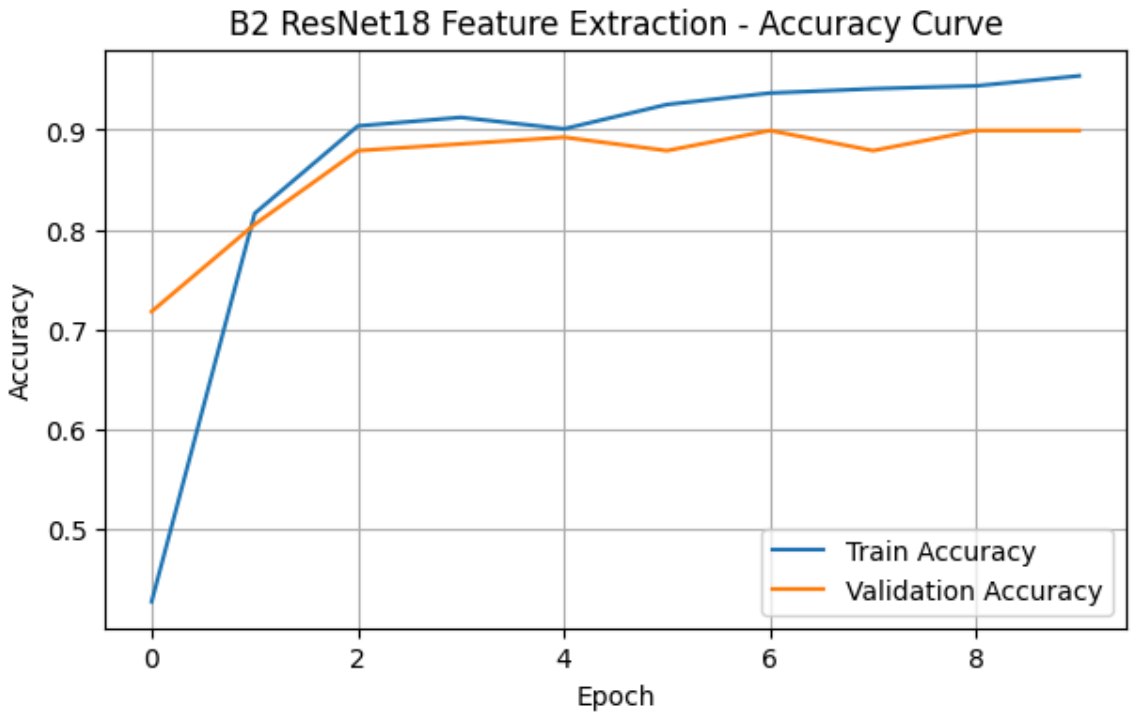


Grafik accuracy B1 menunjukkan peningkatan akurasi training dan validation selama proses pelatihan, tetapi nilai akhirnya masih berada pada tingkat yang rendah dibandingkan eksperimen transfer learning. Akurasi validation mengalami fluktuasi antar epoch yang menunjukkan bahwa model belum mampu menghasilkan representasi fitur yang optimal. Hasil ini sesuai dengan performa akhir B1 yang hanya mencapai accuracy sebesar 36%, sehingga pendekatan training from scratch kurang efektif pada dataset kecil.

4.2 Training Curve B2

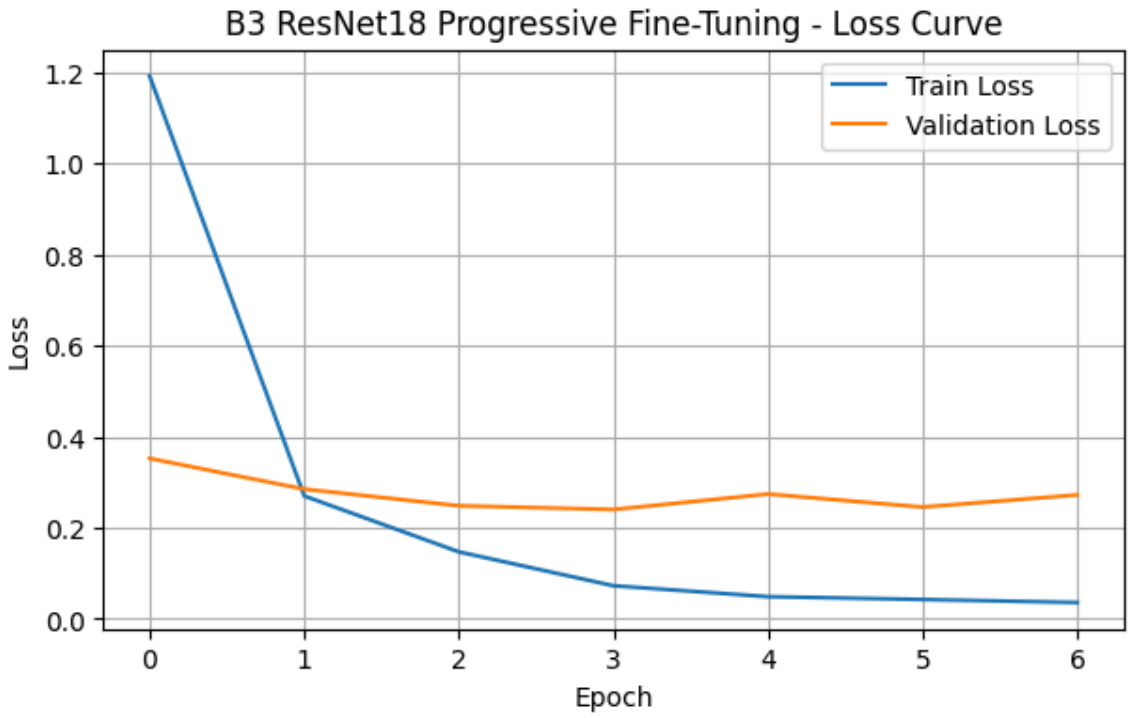


Pada eksperimen B2 menggunakan metode feature extraction, grafik menunjukkan penurunan loss yang lebih cepat dibandingkan B1. Hal ini terjadi karena backbone ResNet18 telah menggunakan bobot pretrained ImageNet sehingga model sudah memiliki fitur dasar seperti edge, tekstur, dan pola visual. Validation loss juga mengalami penurunan yang stabil, menunjukkan bahwa model mampu melakukan adaptasi terhadap dataset target dengan baik.

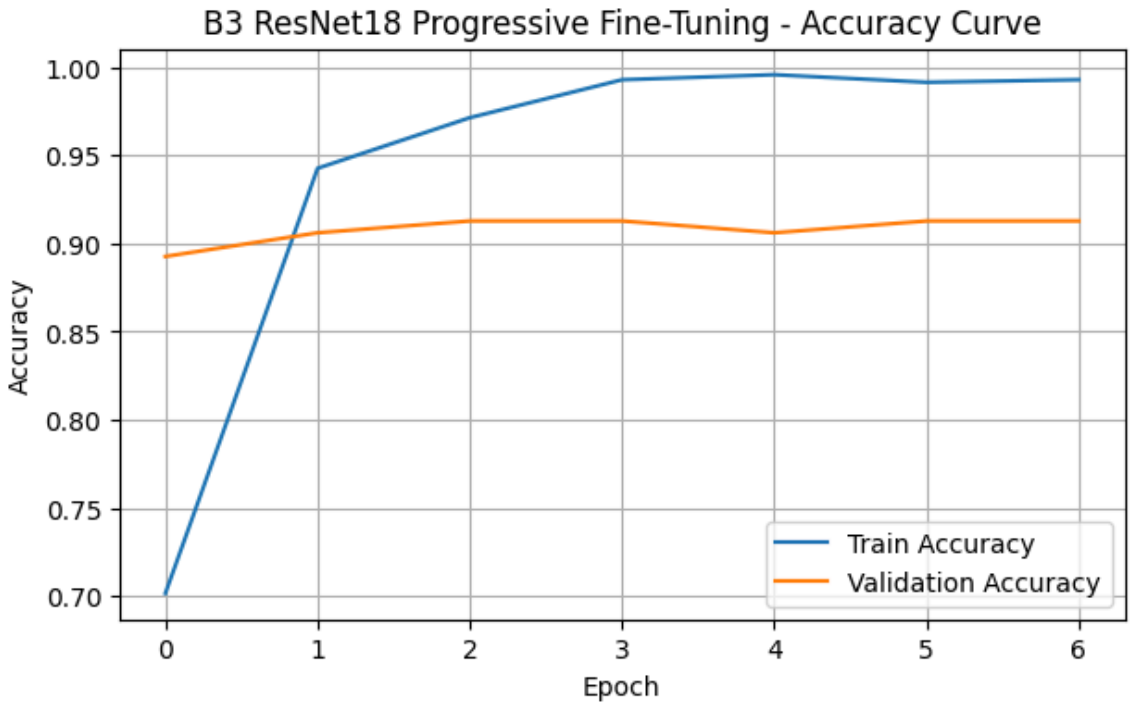


Grafik accuracy B2 menunjukkan peningkatan performa yang signifikan sejak awal training. Akurasi validation meningkat hingga mendekati 90%, menunjukkan bahwa fitur pretrained dari ImageNet mampu membantu proses klasifikasi pada dataset Oxford-IIIT Pet. Hasil akhir eksperimen ini mencapai test accuracy sebesar 98.67% dan Macro F1 sebesar 0.9867, sehingga feature extraction menjadi salah satu strategi paling efektif pada penelitian ini.

4.3 Training Curve B3



Pada metode progressive fine-tuning, loss training mengalami penurunan yang sangat cepat pada beberapa epoch awal. Hal ini menunjukkan bahwa pembukaan sebagian layer backbone memungkinkan model melakukan adaptasi fitur tingkat tinggi terhadap dataset target. Validation loss relatif stabil meskipun terdapat sedikit perubahan antar epoch. Strategi ini berhasil mempertahankan kemampuan fitur pretrained sekaligus melakukan penyesuaian terhadap karakteristik dataset.



Grafik accuracy B3 menunjukkan peningkatan akurasi training hingga mendekati 100%, sedangkan validation accuracy stabil pada kisaran 90% ke atas. Perbedaan antara training dan validation accuracy menunjukkan adanya sedikit indikasi overfitting, namun performa generalisasi model tetap sangat baik. Model B3 memperoleh test accuracy sebesar 98.67% dengan Macro F1 sebesar 0.9866.

4.4 Analisis Data Augmentation (B4)

Perbandingan performa:

Tanpa Augmentation: Accuracy 98.00%, Macro F1 0.97998
Dengan Augmentation: Accuracy 97.33%, Macro F1 0.9735

Berdasarkan hasil perbandingan data augmentation, penggunaan augmentasi tidak memberikan peningkatan performa pada eksperimen ini. Model tanpa augmentation memperoleh accuracy sebesar 98.00%, sedangkan model dengan augmentation memperoleh accuracy sebesar 97.33%. Hal ini menunjukkan bahwa pretrained model sudah memiliki kemampuan ekstraksi fitur yang kuat sehingga tambahan variasi gambar dari augmentation tidak memberikan keuntungan signifikan pada dataset yang digunakan.

Selain itu, ukuran dataset yang relatif kecil menyebabkan beberapa transformasi augmentasi dapat menambahkan variasi yang tidak selalu merepresentasikan pola asli dari data

4.5 Perbandingan EfficientNet-B0

EfficientNet-B0 menghasilkan performa kompetitif dengan jumlah parameter yang lebih kecil Model ini juga memperoleh Macro F1 sebesar 0.9733 sehingga menunjukkan keseimbangan performa antar kelas yang baik dibandingkan ResNet18. Dengan total parameter sebesar 4.020.358 dan trainable parameter 12.810, EfficientNet-B0 mampu mencapai test accuracy sebesar 97.33%. Hasil ini menunjukkan bahwa arsitektur yang lebih ringan tetap mampu memberikan performa tinggi dengan kebutuhan komputasi yang lebih efisien.

5. Analisis Hasil

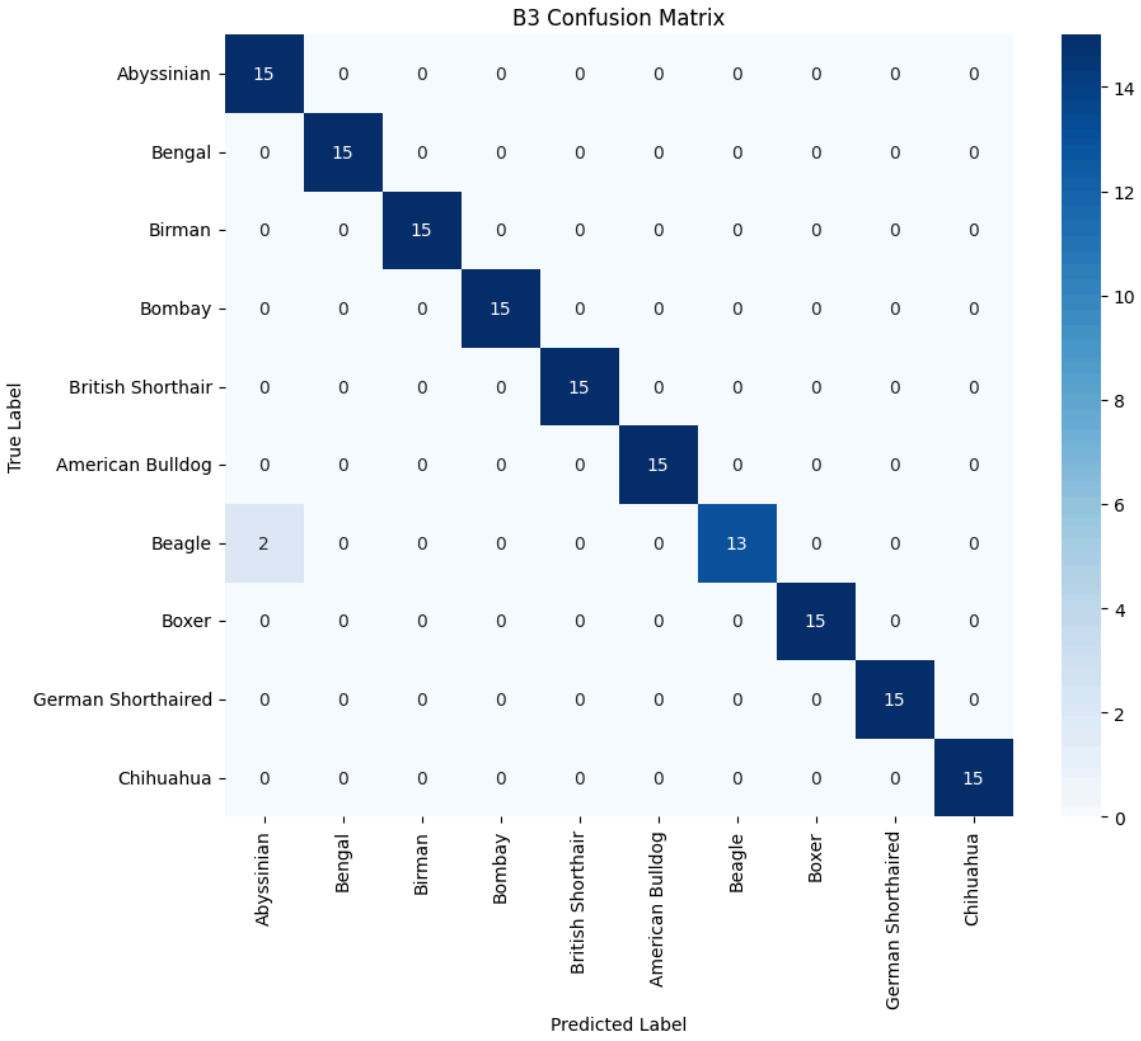
Model B1 menghasilkan performa lebih rendah karena seluruh fitur dipelajari dari awal dengan jumlah data yang terbatas Hal ini terlihat dari test accuracy sebesar 36% dibandingkan model berbasis transfer learning yang mencapai lebih dari 97%. Transfer learning pada B2 dan B3 memberikan peningkatan signifikan karena model telah memiliki representasi fitur visual dari ImageNet.

Walaupun B3 menggunakan progressive fine-tuning dengan parameter trainable yang lebih banyak dibandingkan B2, peningkatan performa tidak terlihat signifikan. Hal ini menunjukkan bahwa feature extraction sudah cukup efektif pada dataset ini karena fitur pretrained ResNet18 telah mampu merepresentasikan karakteristik visual dari kelas yang digunakan.

Hasil B4 menunjukkan bahwa augmentation tidak selalu meningkatkan performa. Pada eksperimen ini, tanpa augmentation memperoleh hasil sedikit lebih tinggi dibandingkan dengan augmentation.

EfficientNet-B0 mampu mencapai accuracy 97.33% dengan jumlah parameter sekitar 4 juta, lebih kecil dibandingkan ResNet18 yang memiliki sekitar 11 juta parameter. Hal ini menunjukkan bahwa EfficientNet-B0 memberikan trade-off yang baik antara performa dan efisiensi komputasi.

6. Confusion Matrix dan Failure Analysis



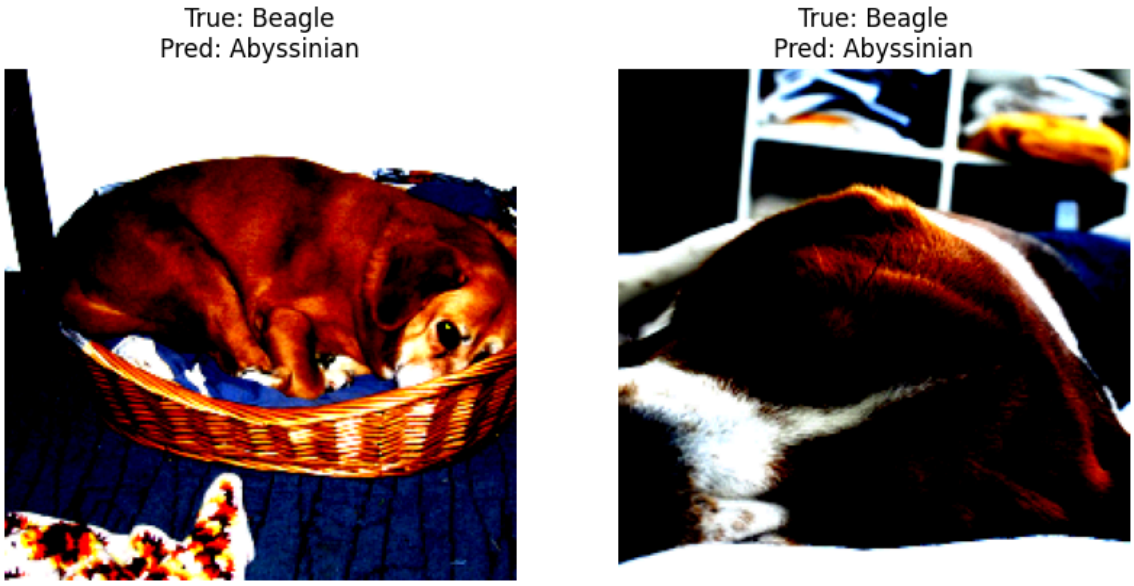
Confusion matrix digunakan untuk melihat performa klasifikasi model pada setiap kelas secara lebih detail. Sumbu vertikal menunjukkan label asli dari gambar, sedangkan sumbu horizontal menunjukkan hasil prediksi model. Nilai pada diagonal utama menunjukkan jumlah prediksi yang benar untuk masing-masing kelas.

Berdasarkan confusion matrix model B3, sebagian besar kelas berhasil diklasifikasikan dengan sempurna. Sebanyak 9 dari 10 kelas memperoleh 15 prediksi benar dari 15 data pengujian pada masing-masing kelas. Hal ini menunjukkan bahwa model mampu mengenali karakteristik visual dari sebagian besar kelas dengan sangat baik.

Kesalahan prediksi hanya ditemukan pada kelas **Beagle**, dimana terdapat 2 gambar Beagle yang salah diprediksi sebagai **Abyssinian**, sementara 13 gambar lainnya berhasil diklasifikasikan dengan benar. Kesalahan ini

kemungkinan disebabkan oleh adanya kemiripan karakteristik visual antara kedua kelas, seperti warna bulu, bentuk tubuh pada sudut tertentu, atau kualitas gambar yang kurang memberikan informasi pembeda.

Secara keseluruhan, confusion matrix menunjukkan bahwa model B3 memiliki kemampuan generalisasi yang sangat baik dengan jumlah kesalahan klasifikasi yang sangat rendah. Hasil ini sesuai dengan performa pengujian dimana model memperoleh test accuracy sebesar 98.67% dan Macro F1 sebesar 0.9866.



Model salah mengklasifikasikan gambar Beagle sebagai Abyssinian. Kesalahan terjadi karena model menangkap fitur visual yang memiliki kemiripan antar kelas.

Berdasarkan hasil evaluasi, ditemukan beberapa contoh kesalahan prediksi pada model B3 Progressive Fine-Tuning. Salah satu kesalahan terjadi pada gambar dengan label asli **Beagle**, namun model memprediksi gambar tersebut sebagai **Abyssinian**.

Kesalahan klasifikasi ini kemungkinan disebabkan oleh adanya kemiripan fitur visual yang ditangkap oleh model. Pada gambar tersebut, model dapat lebih memperhatikan karakteristik tertentu seperti warna dominan bulu, pola tekstur, serta bentuk objek pada sudut pengambilan gambar dibandingkan fitur spesifik yang membedakan ras Beagle dan Abyssinian.

Selain itu, faktor seperti posisi objek yang tidak sepenuhnya terlihat, pencahayaan, serta latar belakang gambar dapat menyebabkan informasi visual yang tersedia menjadi terbatas. Kondisi tersebut membuat fitur yang dipelajari model menjadi kurang mampu membedakan kedua kelas secara optimal.

Meskipun terdapat kesalahan pada beberapa sampel, jumlah kesalahan yang ditemukan sangat kecil dibandingkan keseluruhan data pengujian. Hal ini menunjukkan bahwa model B3 tetap memiliki kemampuan generalisasi yang sangat baik dengan test accuracy sebesar 98.67%.

7. Kesimpulan

Eksperimen menunjukkan bahwa transfer learning memberikan peningkatan performa dibandingkan training from scratch. ResNet18 feature extraction dan progressive fine-tuning menghasilkan performa terbaik. Kedua metode tersebut mencapai test accuracy sebesar 98.67% dengan Macro F1 sekitar 0.986. , sedangkan EfficientNet-B0 memberikan alternatif dengan parameter yang lebih kecil.

Pernyataan Penggunaan AI (AI Disclosure Statement)

Dalam penyusunan tugas ini, penulis menggunakan bantuan **ChatGPT (OpenAI)** sebagai alat bantu dalam proses pengerjaan.

Ruang lingkup penggunaan AI pada tugas ini meliputi:

- Membantu debugging kode Python/PyTorch ketika terdapat error selama proses implementasi.
- Membantu memberikan referensi sintaksis dan struktur kode untuk proses training, evaluasi model, visualisasi, serta penyimpanan log eksperimen.
- Membantu klarifikasi konsep terkait deep learning, transfer learning, feature extraction, progressive fine-tuning, evaluasi model, dan interpretasi metrik.

Seluruh proses eksperimen, eksekusi kode, pengumpulan hasil, analisis performa model, interpretasi hasil empiris, serta penarikan kesimpulan dilakukan dan diverifikasi secara mandiri oleh penulis.

Verifikasi terhadap keluaran AI dilakukan dengan cara:

- Menjalankan kembali kode pada lingkungan eksperimen (Jupyter Notebook/Google Colab).
- Membandingkan hasil keluaran kode dengan metrik evaluasi aktual seperti test loss, accuracy, dan Macro F1.
- Memeriksa kesesuaian hasil eksperimen dengan visualisasi, confusion matrix, dan log hasil pelatihan.

- Melakukan pengecekan ulang terhadap konsep dan implementasi sebelum dimasukkan ke laporan.

AI digunakan sebagai alat bantu teknis dan pembelajaran, bukan sebagai pengganti proses analisis dan pemahaman penulis terhadap eksperimen yang dilakukan.

Link GITHUB :https://github.com/alifagil/Deep-Learning-GSLC05